

IMPLEMENTACIÓN DE PIPELINE ML END-TO-END

MLOps aplicado a clasificación de cáncer de mama

Autor: **Tapia Ramos Arturo Eyck**

Docente: **Manases Antoni Mauricio Condori**

Curso: **Entrenamiento Práctico en Ciencia de Datos-MCDSP4-1-V20241**

Fecha: **29/04/26**



Universidad Católica
San Pablo

1. Resumen Ejecutivo

Este documento describe el diseño e implementación de un pipeline de Machine Learning end-to-end orientado a la clasificación de tumores de mama como benignos o malignos. El sistema fue desarrollado bajo principios de MLOps, incluyendo reproducibilidad, automatización, versionado de modelos y monitoreo continuo.

El modelo implementado demuestra un alto desempeño predictivo, alcanzando métricas superiores al 98% en accuracy, precision y recall. Asimismo, la solución ha sido diseñada con enfoque productivo, integrando una API para inferencia y mecanismos básicos de monitoreo.

Desde una perspectiva de negocio, el sistema permite mejorar procesos de triage clínico, priorizando casos críticos y reduciendo tiempos de respuesta.

2. Problema de Negocio y Objetivo Analítico

En el contexto clínico, la identificación temprana de tumores malignos es crítica para mejorar la probabilidad de supervivencia de los pacientes. Sin embargo, los procesos manuales pueden generar retrasos en la priorización de casos.

El objetivo del proyecto es desarrollar un modelo predictivo capaz de estimar la probabilidad de malignidad de un tumor a partir de características biomédicas. Esto permite asistir a profesionales de la salud en la toma de decisiones, optimizando la asignación de recursos.

El problema se aborda como una tarea de clasificación supervisada binaria utilizando datos estructurados.

3. Arquitectura del Pipeline

El pipeline implementado sigue una arquitectura modular:

ingesta → preprocesamiento → entrenamiento → evaluación → registro → despliegue → monitoreo

Cada componente está diseñado para ser reproducible y desacoplado, permitiendo su ejecución independiente y facilitando la mantenibilidad del sistema.

Esta arquitectura sigue buenas prácticas de MLOps, asegurando trazabilidad completa del ciclo de vida del modelo.

4. Implementación Técnica

El desarrollo se realizó utilizando un stack moderno de herramientas orientadas a ciencia de datos y despliegue de modelos.


Se empleó Python como lenguaje principal, junto con bibliotecas como pandas y scikit-learn para manipulación de datos y modelado. El modelo consiste en un pipeline que incluye StandardScaler para normalización y LogisticRegression como algoritmo de clasificación.

Para la gestión del ciclo de vida del modelo se utilizó MLflow, permitiendo registrar métricas, parámetros y artefactos. El despliegue se realizó mediante FastAPI, exponiendo el modelo como un servicio REST.

Finalmente, Docker y Docker Compose permiten la reproducibilidad del entorno y facilitan el despliegue en diferentes infraestructuras.

5. Resultados del Modelo

El modelo entrenado presenta un desempeño sobresaliente:



The screenshot displays the MLflow interface for a run named 'baseline-logistic-regression'. The 'Overview' tab is active, showing a table of metrics and a list of parameters. The metrics table includes accuracy, precision, recall, f1_score, and roc_auc, all with values around 0.98-0.99. The parameters table lists model_type as LogisticRegression, test_size as 0.2, and random_state as 42. The right sidebar provides details about the run, including its creation time, creator (root), experiment ID, status (Finished), run ID, duration (1.6s), source (cli.py), and registered prompts (none). It also shows no datasets and one tag (BreastCancerClassifier v1).

Metric	Value	Models
accuracy	0.9824561403508771	model
precision	0.9861111111111112	model
recall	0.9861111111111112	model
f1_score	0.9861111111111112	model
roc_auc	0.9953703703703703	model

Parameter	Value
model_type	LogisticRegression
test_size	0.2
random_state	42

Created at	04/29/2026, 10:56:19 AM
Created by	root
Experiment ID	1
Status	Finished
Run ID	2c06d3bc8a814a0690abb230f691be23
Duration	1.6s
Source	cli.py
Registered prompts	—

Datasets	None
----------	------

Tags	Add tags
------	----------

Registered models	BreastCancerClassifier v1
-------------------	---------------------------

Estos resultados indican una alta capacidad del modelo para discriminar entre tumores benignos y malignos, minimizando tanto falsos positivos como falsos negativos.

Es importante destacar que estos valores se obtuvieron sobre un conjunto de prueba separado, garantizando la validez de la evaluación.

6. Despliegue e Inferencia

El modelo fue desplegado mediante una API REST utilizando FastAPI. Esto permite que otros sistemas puedan consumir el modelo de forma sencilla mediante solicitudes HTTP.

Se implementaron endpoints clave como /health para verificación del servicio, /model/info para obtener información del modelo y /predict para realizar inferencias.

La documentación interactiva facilita la exploración y pruebas del servicio, mejorando la usabilidad para desarrolladores y analistas.

7. Monitoreo y Trazabilidad

Se implementó un sistema básico de monitoreo para detectar posibles desviaciones en los datos de entrada. Para ello se utilizó la prueba estadística KS (Kolmogorov-Smirnov), aplicada a cada variable.

Adicionalmente, todas las predicciones son registradas en archivos de log, permitiendo auditoría posterior. También se generan reportes automáticos en formato JSON.

En pruebas iniciales se detectó posible drift en algunas variables, lo cual valida el funcionamiento del sistema de monitoreo.

8. Valor de Negocio

La solución desarrollada aporta valor significativo:

- Permite priorizar pacientes de alto riesgo
- Reduce tiempos de respuesta en diagnóstico
- Mejora la consistencia en la evaluación clínica
- Facilita auditoría y trazabilidad del modelo
- Sienta las bases para sistemas productivos escalables

Esto convierte al sistema en una herramienta estratégica para organizaciones de salud.

9. Conclusiones

El pipeline desarrollado cumple con los principios fundamentales de MLOps y demuestra ser una solución robusta y efectiva para problemas de clasificación médica.

El sistema no solo alcanza alto desempeño técnico, sino que también está preparado para su integración en entornos reales, aportando valor tangible.

Como trabajo futuro, se podrían incorporar técnicas más avanzadas de monitoreo, así como validación continua en datos reales.